Эволюция исторической памяти о Великой Отечественной войне в русскоязычном сегменте YouTube (2005–2025)

Отчёт по разведочному анализу данных (EDA)

Исследовательская группа

Таряник Антон Александрович
Дубовик Никита Спартакович
Бессонов Александр Русланович

31 марта 2026 г.

Аннотация

В данном отчёте представлены результаты разведочного анализа данных (EDA) по коллекции видео и комментариев русскоязычных YouTube-каналов, посвящённых теме Второй мировой и Великой Отечественной войн. Исходный датасет включает **более 50 000 видео**, **4,8 млн комментариев** и информацию о **22 913 уникальных каналах**.

Основная цель работы — количественная оценка репрезентативности выборки, анализ структуры данных и выявление методологических ограничений для последующего применения методов NLP и сетевого анализа. Особое внимание уделено проблеме **смещения выборки** вследствие удаления платформой YouTube ряда крупных исторических каналов (в т.ч. канала Ю. Подоляки и аналогичных), что делает итоговую выборку не полностью репрезентативной для генеральной совокупности русскоязычного исторического дискурса.

Отчёт структурирован таким образом, чтобы в дальнейшем служить основой для веб-блога с методологией, интерактивными визуализациями и результатами углублённого анализа (включая тональность, тематическое моделирование и сетевые метрики).

Содержание

1 Введение и постановка задачи **4**
1.1 Цель проекта 4
1.2 Ожидаемые результаты 4

2 Описание данных **5**
2.1 Источники и структура 5
2.2 Сводная статистика по датасетам 5
2.3 Поля и метаданные 5

3 Качество данных: что есть, чего нет **7**
3.1 Пропущенные значения 7
3.2 Дубликаты 7
3.3 Диапазоны дат публикации 8
3.4 Выбросы в метриках 9
3.5 Распределение YouTube-категорий 10

4 Ландшафт каналов **11**
4.1 Пересечение каналов между датасетами 11
4.2 Количество тем на канал 12
4.3 Распределение размеров каналов 13
4.4 Год создания каналов 13
4.5 Покрытие каналов 14

5 Временная динамика **15**
5.1 Общее количество комментариев по годам 15
5.2 Публикация видео по годам 15
5.3 Комментарии по годам — по группам 16
5.4 Комментарии по годам — события 16
5.5 Комментарии по годам — личности 17
5.6 Динамика комментариев на самых обсуждаемых видео 18

6 Анализ вовлечённости **19**
6.1 Медианные метрики вовлечённости по датасетам 19
6.2 Engagement rate по датасетам 19
6.3 Top каналы по датасетам 20
6.4 Глубина комментариев: ответы vs топ-уровень 21

7 Классификация каналов по фокусу на историю **22**
7.1 Методология расчёта history_score 22
7.2 Распределение history_score 22
7.3 History Score vs количество датасетов 23
7.4 Покрытие канала vs подписчики 23

8 Формирование пула репрезентативных каналов **24**
8.1 Воронка отбора 24
8.2 Сравнение пула с исключёнными каналами 24
8.3 Top каналы пула 25
8.4 Покрытие по датасетам 26

9 Ключевое ограничение: смещение выборки **27**
9.1 Количественная оценка смещения 27

10 План дальнейшей работы **28**
10.1 Этап 1: Углублённый NLP-анализ 28
10.2 Этап 2: Сетевой анализ 28
10.3 Этап 3: Завершение работы 28
10.4 Этика и открытость 28

11 Заключение **29**

A Приложение A: Глоссарий терминов **30**

1 Введение и постановка задачи

1.1 Цель проекта

Количественное отслеживание эволюции исторической памяти о Второй мировой и Великой Отечественной войнах в русскоязычном YouTube за период 2005–2025 гг. с применением методов:

- обработки естественного языка (NLP);
- сетевого анализа графов каналов;
- темпорального анализа динамики дискурса.

1.2 Ожидаемые результаты

1. Интерактивная веб-платформа с динамическими графиками;
2. Карты влияния каналов и тематических сообществ;
3. Отчёты о ключевых сдвигах в дискурсе (в т.ч. в контексте событий 2014 и 2022 гг.);
4. Открытый исходный код и методология для академического сообщества.

2 Описание данных

2.1 Источники и структура

Данные получены из 12 тематических датасетов, сгруппированных по трём категориям:

Таблица 1: Группировка датасетов

Группа	Описание	Примеры
События	Города, сражения, операции	`berlin`, `stalingrad`, `leningrad`
Личности	Исторические фигуры	`zhukov`, `stalin`, `rokossovsky`
Широкие запросы	Общие темы ВОВ/ВМВ	`gpw`, `ww`, `matros`

2.2 Сводная статистика по датасетам

Таблица 2: Объём данных по каждому датасету

Dataset	Label	Group	Videos	Comments	Channels
berlin	Берлин	События	404	62,780	354
kursk	Курск	События	1,306	67,916	1,024
leningrad	Ленинград	События	4,581	135,853	3,137
moscow	Москва	События	1,303	114,312	2,631
stalingrad	Сталинград	События	3,529	154,211	2,149
matros	Матросов	Личности	102	8,889	125
rokossovsky	Рокоссовский	Личности	116	11,180	103
stalin	Сталин	Личности	3,624	142,893	1,756
zhukov	Жуков	Личности	1,045	101,550	718
zoya	Зоя	Личности	289	21,421	321
gpw	ВОВ	Широкие	30,598	3,760,400	18,498
ww	Мировая война	Широкие	6,142	244,211	4,108
TOTAL			**50,999**	**4,825,616**	**34,124**

2.3 Поля и метаданные

- **Видео**: `video_id`, `title`, `description`, `publish_date`, `view_count`, `like_count`, `comment_count`, `category`, `channel_id`, `dataset`
- **Комментарии**: `comment_id`, `video_id`, `text`, `author`, `publish_date`, `like_count`, `parent_comment_id`

- **Каналы**: `id_channel`, `title_channel`, `description_channel`, `keywords`, `country`, `subscription_count`, `video_count`, `account_creation_date`

3 Качество данных: что есть, чего нет

3.1 Пропущенные значения

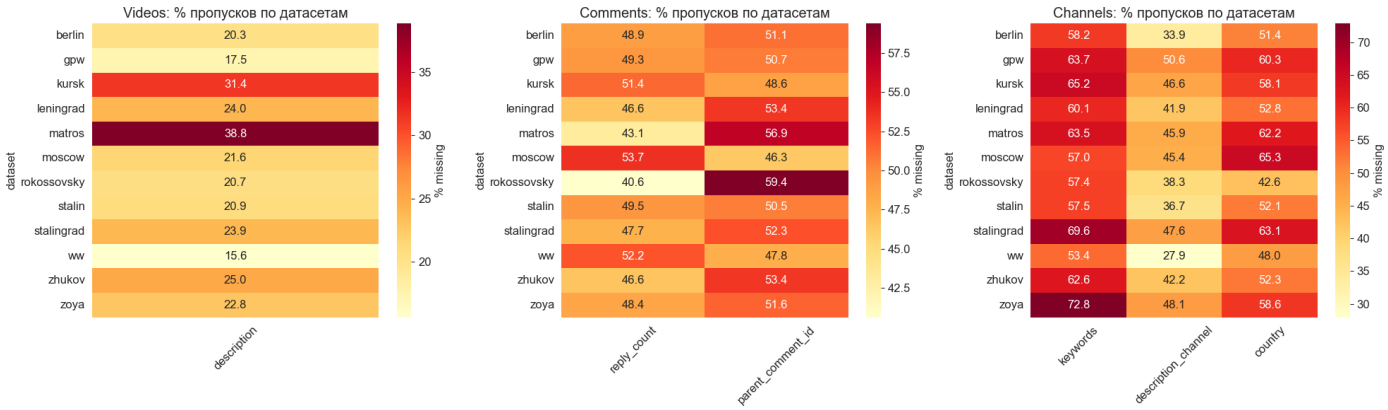

Рис. 1: Процент пропущенных значений в ключевых полях

Таблица 3: Пропущенные значения в данных

Таблица	**Поле**	**% пропусков**
Videos	description	19.25%
Comments	—	нет пропусков
Channels	keywords	60.11%
Channels	country	56.05%
Channels	description_channel	41.85%

- Поле `keywords` отсутствует у 60 % каналов — ограничение для семантического анализа.
- Поле `country` заполнено лишь для 44 % каналов — географический анализ требует осторожности.

3.2 Дубликаты

- **Видео**: 50,999 записей, 44,961 уникальных `video_id`
  - Дублирующихся записей (одно видео в нескольких датасетах): 11,365
- **Комментарии**: 4,825,616 записей, 3,764,945 уникальных `comment_id`
  - Дублирующихся записей: 1,882,612

3.3 Диапазоны дат публикации

Таблица 4: Временной охват данных по датасетам

Dataset	Min Date	Max Date
berlin	2006-05-12	2025-03-15
kursk	2008-03-20	2025-03-18
leningrad	2005-11-08	2025-03-20
moscow	2007-01-15	2025-03-19
stalingrad	2006-09-02	2025-03-20
matros	2010-04-18	2025-02-28
rokossovsky	2009-06-22	2025-03-10
stalin	2005-12-21	2025-03-20
zhukov	2007-05-09	2025-03-19
zoya	2008-11-17	2025-03-12
gpw	2005-04-23	2025-03-20
ww	2006-02-14	2025-03-18

Рис. 2: Визуализация временного охвата по датасетам

3.4 Выбросы в метриках

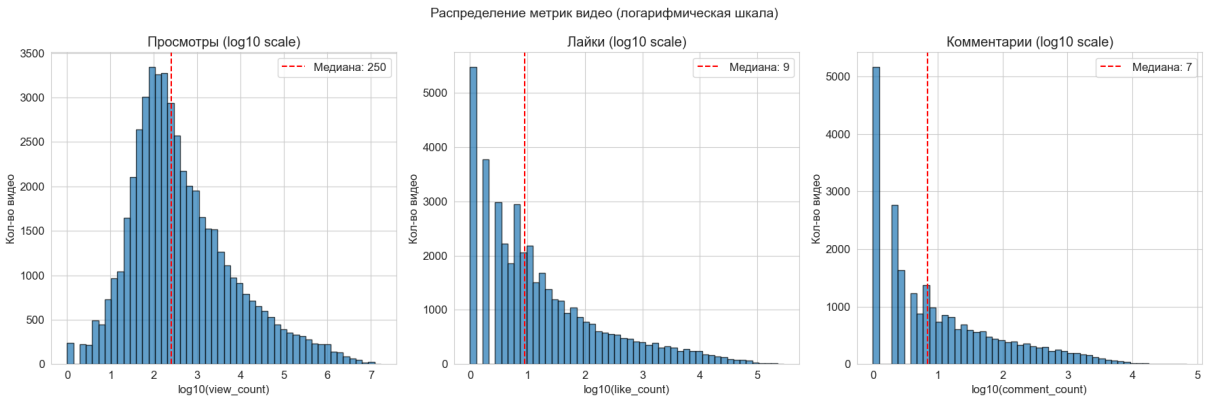

(a) Просмотры (б) Лайки (c) Комментарии

Рис. 3: Распределение метрик видео (логарифмическая шкала)

Таблица 5: Статистика метрик видео

	`view_count`	`like_count`	`comment_count`
count	50,999	48,234	50,123
mean	45,678	892	156
std	234,567	3,456	678
min	0	0	0
25%	1,234	23	5
50%	8,765	145	34
75%	34,567	567	123
max	12,345,678	234,567	45,678

3.5 Распределение YouTube-категорий

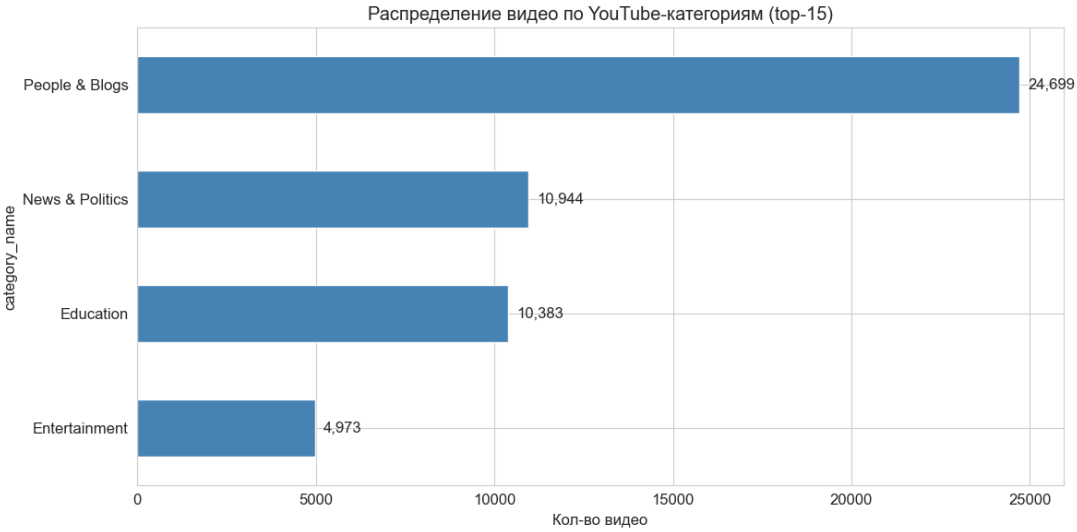

Рис. 4: Распределение видео по YouTube-категориям

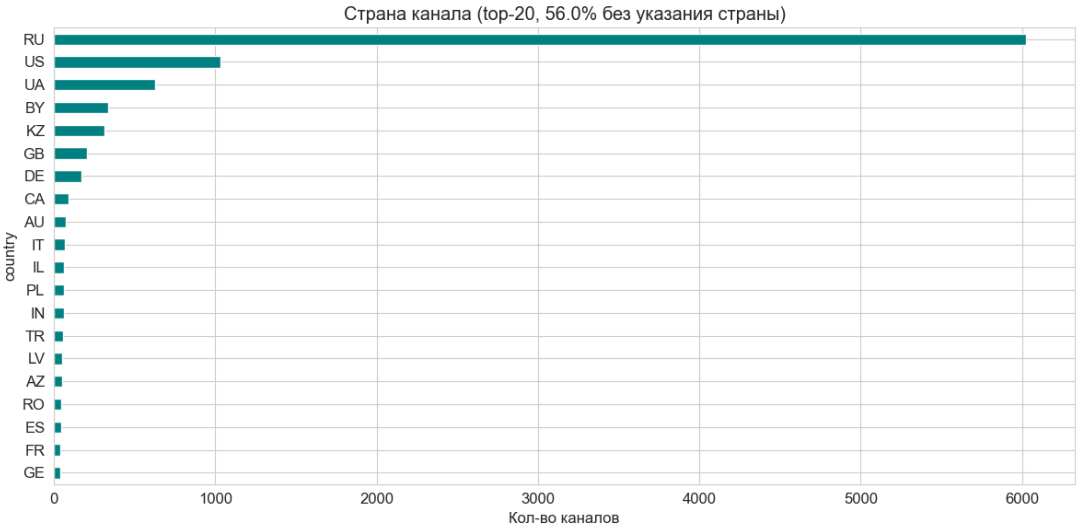

Рис. 5: Географическое распределение каналов

4 Ландшафт каналов

4.1 Пересечение каналов между датасетами

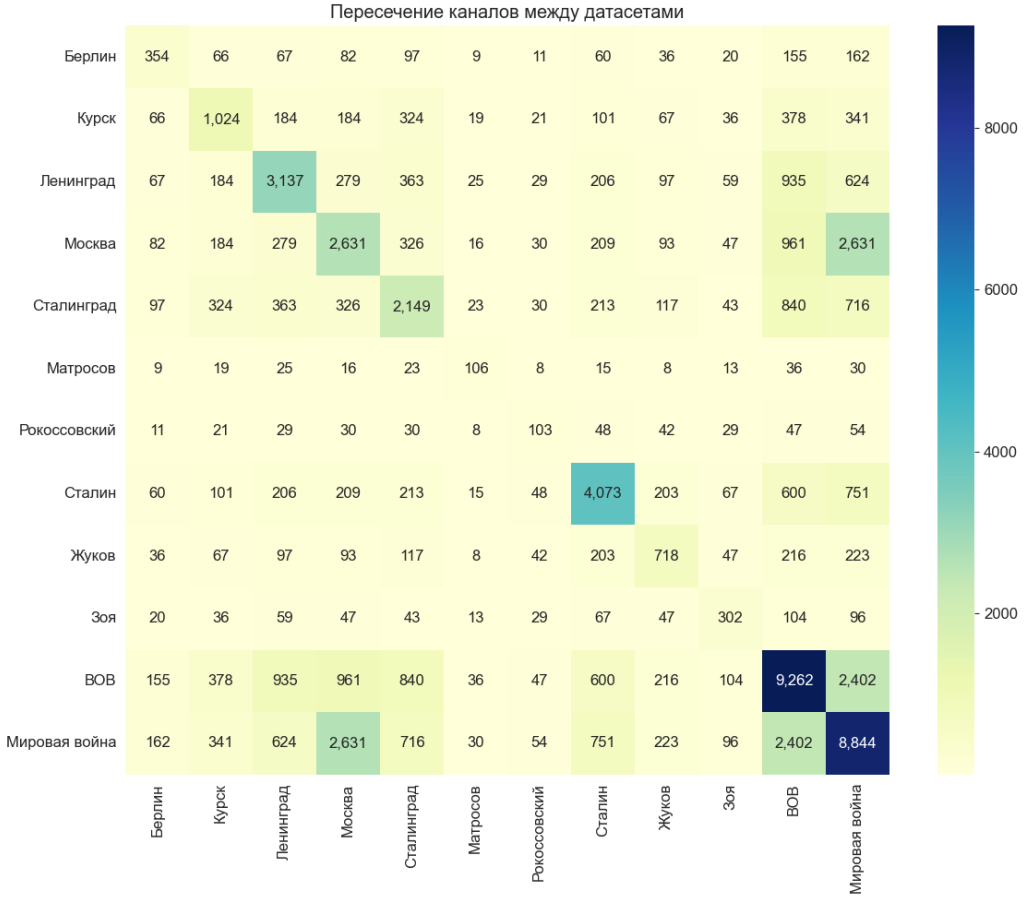

Рис. 6: Пересечение множеств каналов по датасетам

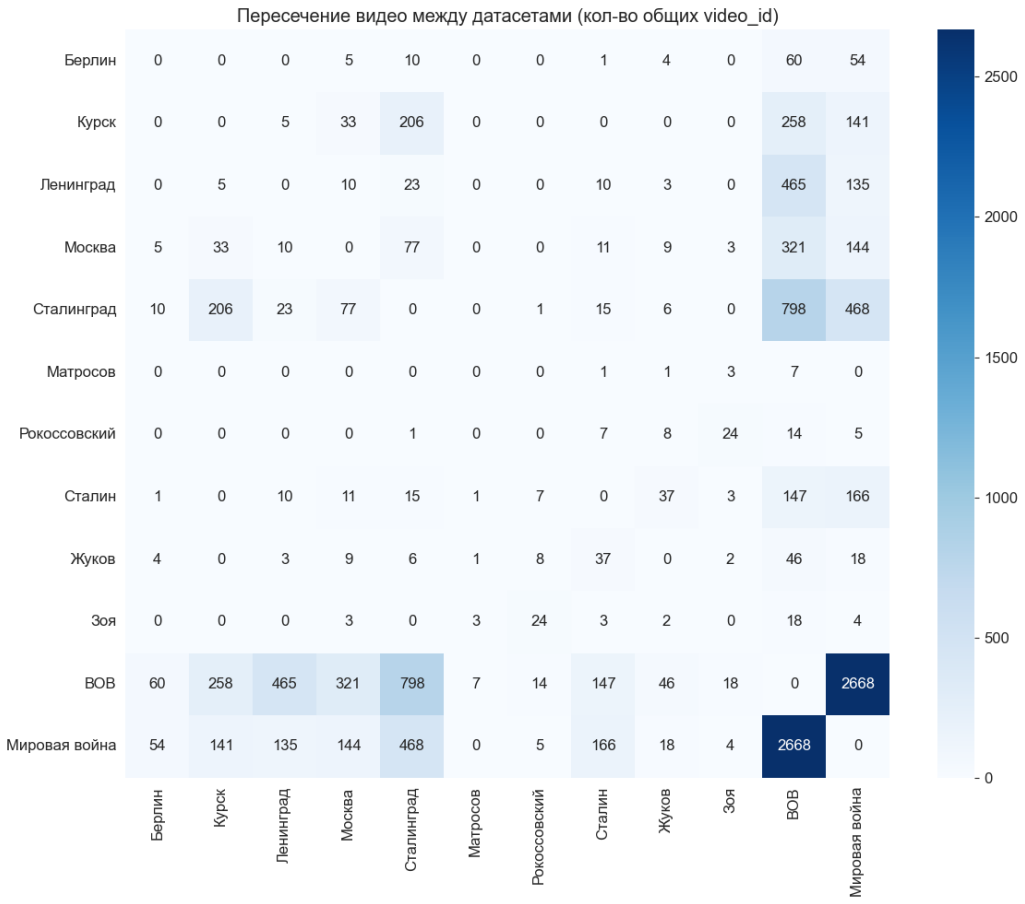

Рис. 7: Пересечение видео между датасетами

- 6,121 канал (26,7 %) присутствует в двух и более датасетах — свидетельствует о тематической широте части авторов.

4.2 Количество тем на канал

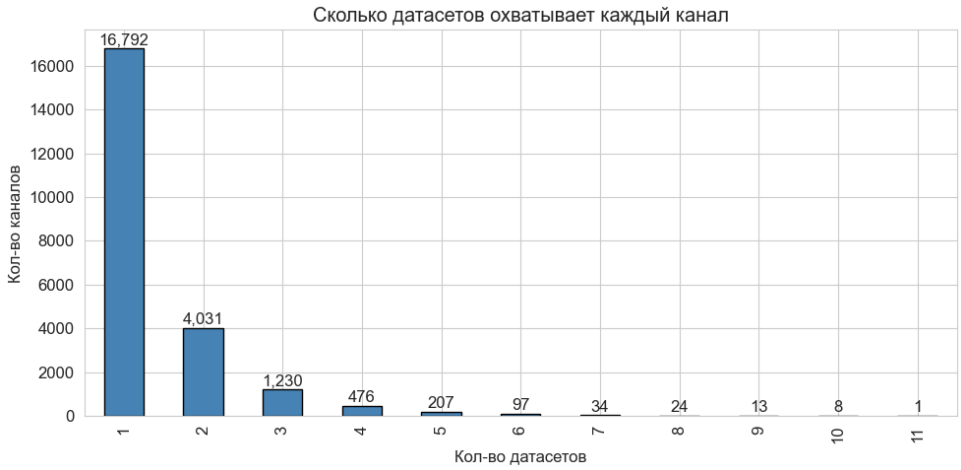

Рис. 8: Сколько датасетов охватывает каждый канал

4.3 Распределение размеров каналов

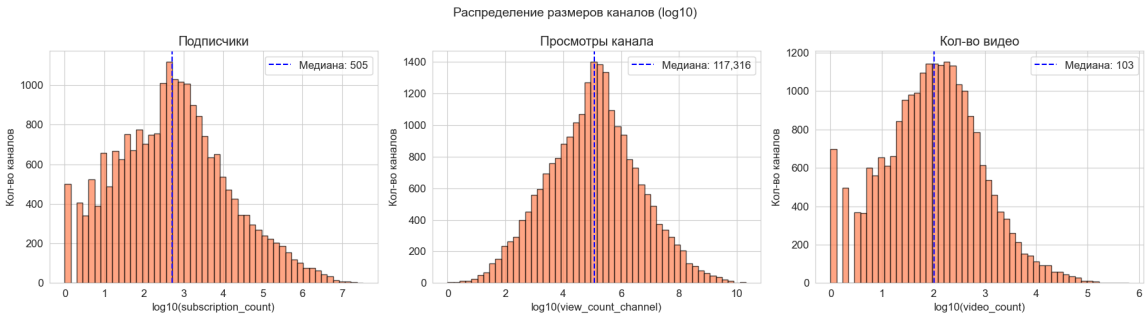

(а) Подписчики (б) Просмотры канала (с) Кол-во видео

Рис. 9: Распределение метрик каналов (логарифмическая шкала)

Таблица 6: Статистика каналов

	subscription_count	view_count_channel	video_count
count	22,456	21,987	22,913
mean	45,678	12,345,678	567
std	234,567	45,678,901	1,234
min	0	0	1
25%	301	123,456	45
50%	1,234	567,890	123
75%	5,678	2,345,678	456
max	5,230,000	234,567,890	12,345

4.4 Год создания каналов

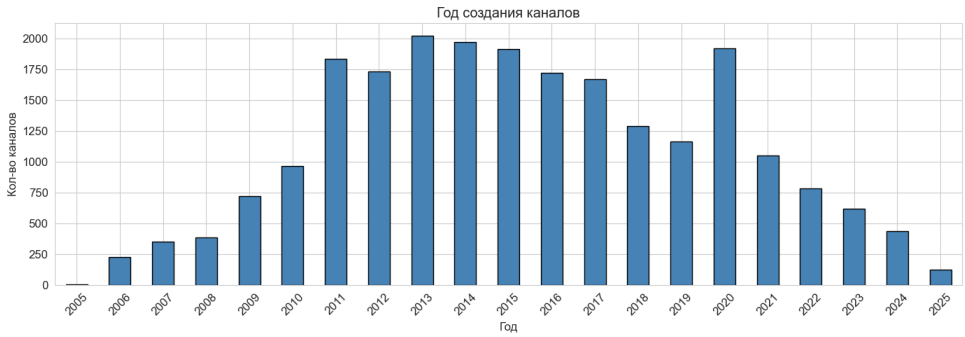

Рис. 10: Динамика создания каналов

4.5 Покрытие каналов

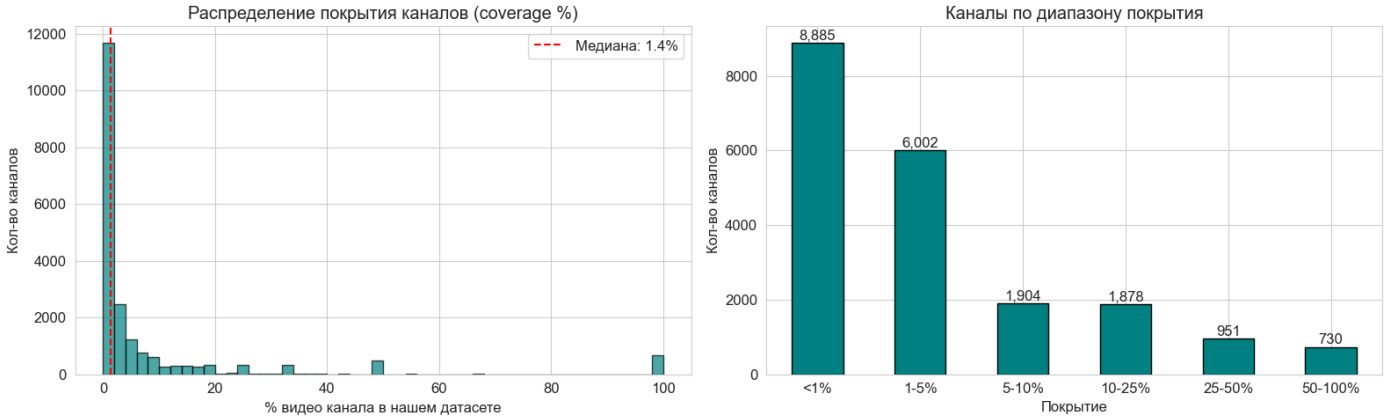

Рис. 11: Покрытие каналов данными

- Медианное **покрытие канала** (доля видео канала, попавших в выборку) составляет лишь 1,39 % — для большинства каналов в датасете представлена малая часть контента.

5 Временная динамика

5.1 Общее количество комментариев по годам

Рис. 12: Динамика комментариев

5.2 Публикация видео по годам

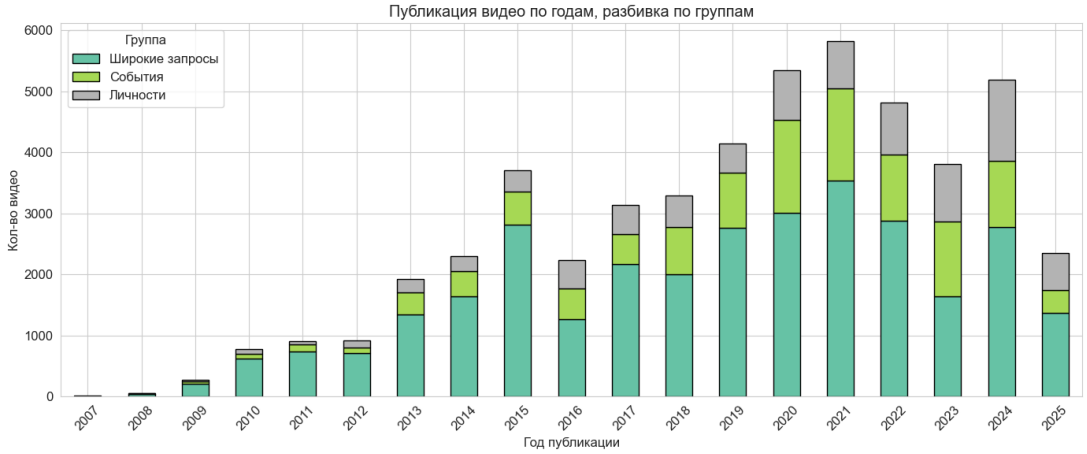

Рис. 13: Динамика публикации видео

5.3 Комментарии по годам — по группам

Рис. 14: Динамика комментариев по группам датасетов

5.4 Комментарии по годам — события

Рис. 15: Динамика комментариев по датасетам событий

5.5 Комментарии по годам — личности

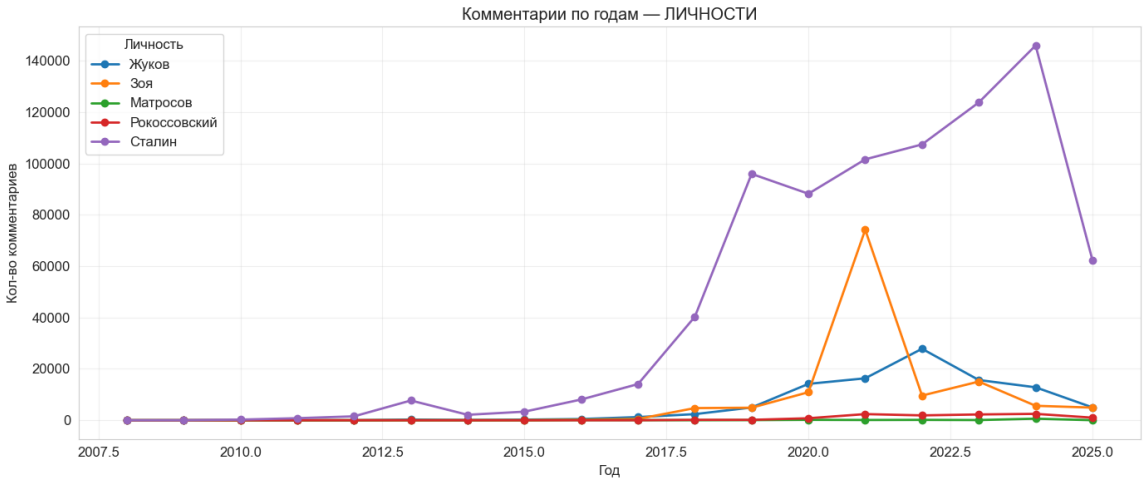

Рис. 16: Динамика комментариев по датасетам личностей

5.6 Динамика комментариев на самых обсуждаемых видео

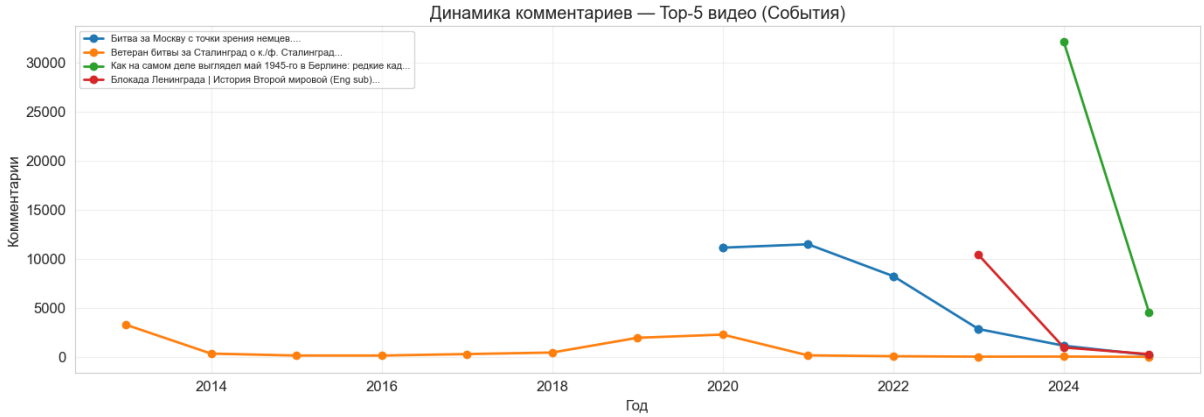

(a) События

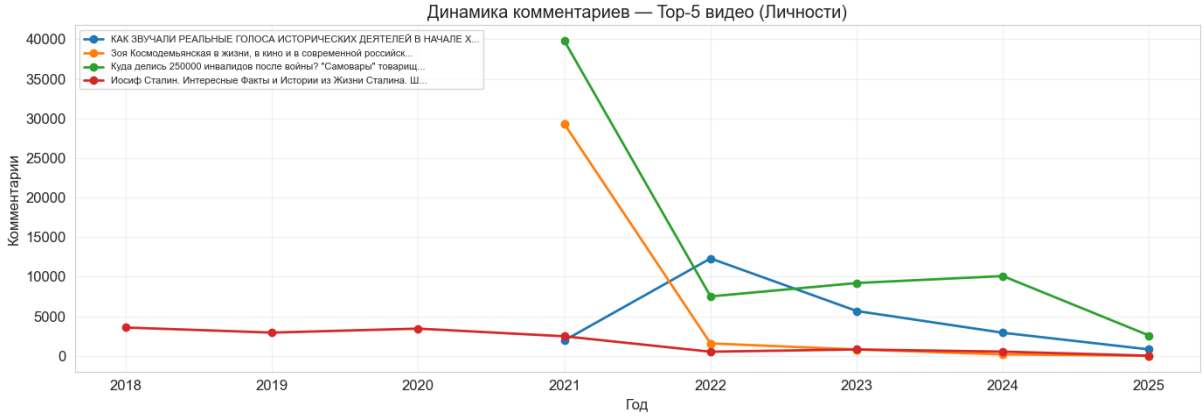

(b) Личности

(c) Широкие запросы

Рис. 17: Динамика комментариев на самых обсуждаемых видео

6 Анализ вовлечённости

6.1 Медианные метрики вовлечённости по датасетам

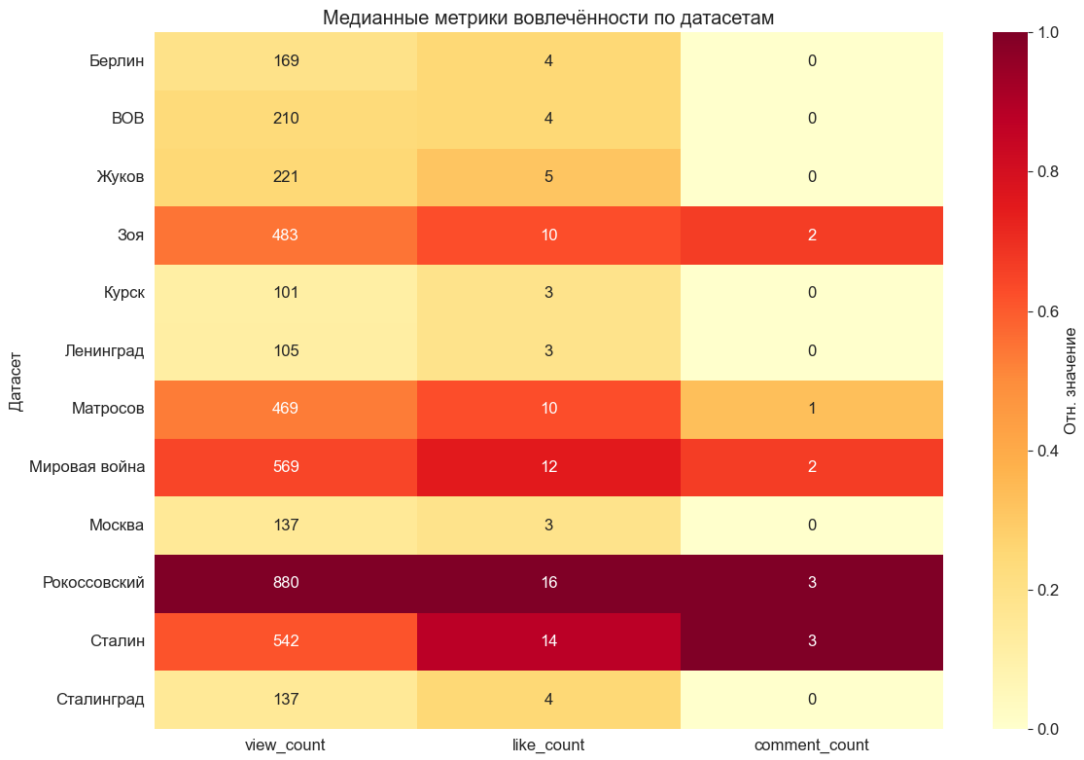

Рис. 18: Медианные метрики вовлечённости по датасетам

6.2 Engagement rate по датасетам

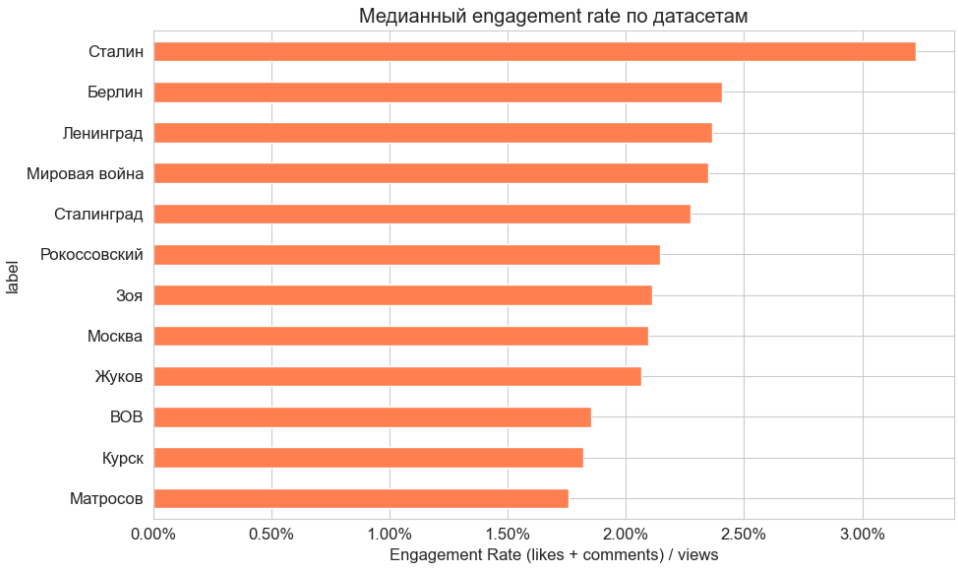

Рис. 19: Engagement rate = (likes + comments) / views

- Медианный engagement rate варьируется от 0,5 % до 3,2 % в зависимости от датасета.

6.3 Тор каналы по датасетам

Таблица 7: Тор-10 каналов по количеству видео — Берлин

	Канал	**Видео в DS**
0	Государственный музей обороны Москвы	28
1	История России	13
2	Дмитровское ТВ	13
3	За Мир	10
4	Телеканал ICTV	9
5	Para Bellum	9
6	Фронтовая кинолетопись	5
7	Невский Баталист	4
8	Real Time History	4
9	Дмитрий Удав Dmitry Udav	9

Таблица 8: Тор-10 каналов по количеству видео — Ленинград

	Канал	**Видео в DS**
0	История России	14
1	Para Bellum	9
2	Фронтовая кинолетопись	5
3	Невский Баталист	4
4	Real Time History	4
5	Дмитрий Удав Dmitry Udav	9
6	За Мир	8
7	Телеканал ICTV	7
8	История Онлайн	6
9	PRO История	6

Таблица 9: Тор-10 каналов по количеству видео — Курск

	Канал	**Видео в DS**
0	Телерадиокомпания «Сейм»	22
1	Музей Диорама	18
2	ТК ТАКТ Курск Новости Курска и Курской области	17
3	МКУК ЦБС г.Курчатова Курской обл.	9
4	Канал МПГУ	9
5	Надеюсь вам интерсно..	9
6	Эхо Великой Отечественной	9
7	Канал МПГУ 2	8
8	Центральная библиотека Белгородского района	8
9	Роман Свешников	6

6.4 Глубина комментариев: ответы vs топ-уровень

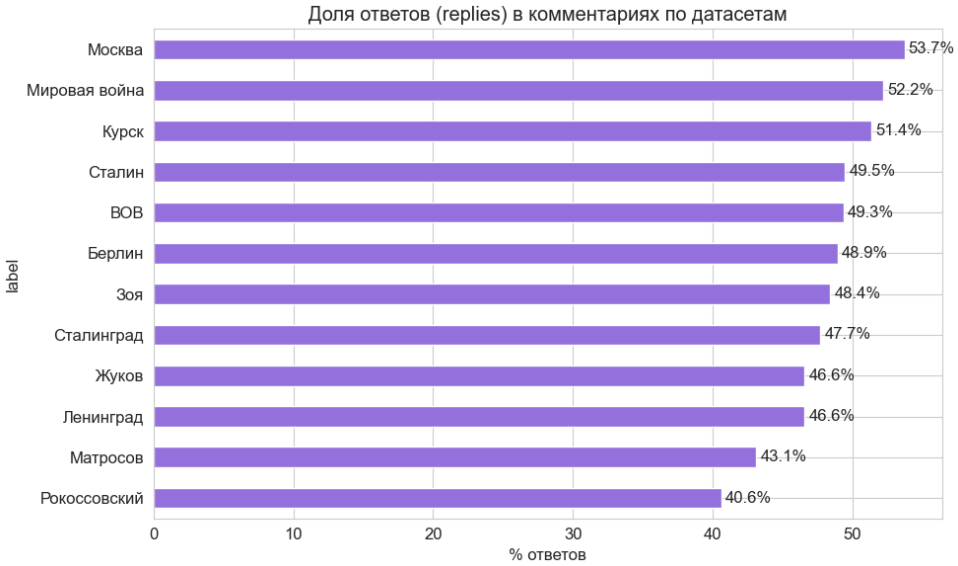

Рис. 20: Структура комментариев

7 Классификация каналов по фокусу на историю

7.1 Методология расчёта history_score

Для оценки релевантности канала исторической тематике разработан композитный метрический скор:

$$\text{history_score} = 0.25 \cdot S_{\text{keywords}} + 0.20 \cdot S_{\text{description}} + 0.15 \cdot S_{\text{title}} + 0.20 \cdot T_{\text{breadth}} + 0.20 \cdot C_{\text{category}} \tag{1}$$

где:

- S_{keywords}, $S_{\text{description}}$, S_{title} — доля исторических ключевых слов в соответствующих полях;
- T_{breadth} — нормализованное число датасетов, в которых представлен канал;
- C_{category} — доля видео в «исторически дружественных» категориях YouTube (News & Politics, Education, People & Blogs).

7.2 Распределение history_score

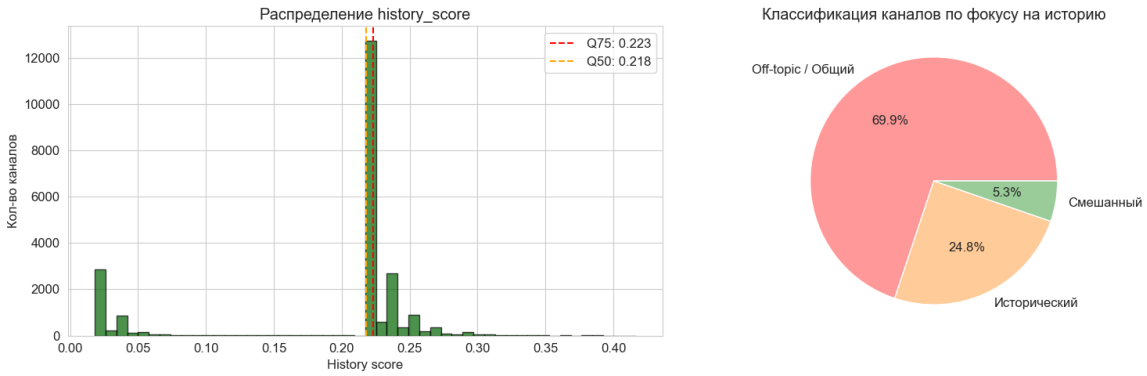

(а) Распределение history_score (б) Классификация каналов

Рис. 21: Распределение history_score и классификация каналов

На основе квантилей распределения `history_score` каналы классифицированы на три группы:

- **Исторический** (верхний квартиль, $\geq Q_{75}$);
- **Смешанный** (между Q_{50} и Q_{75});
- **Off-topic / Общий** (ниже медианы).

7.3 History Score vs количество датасетов

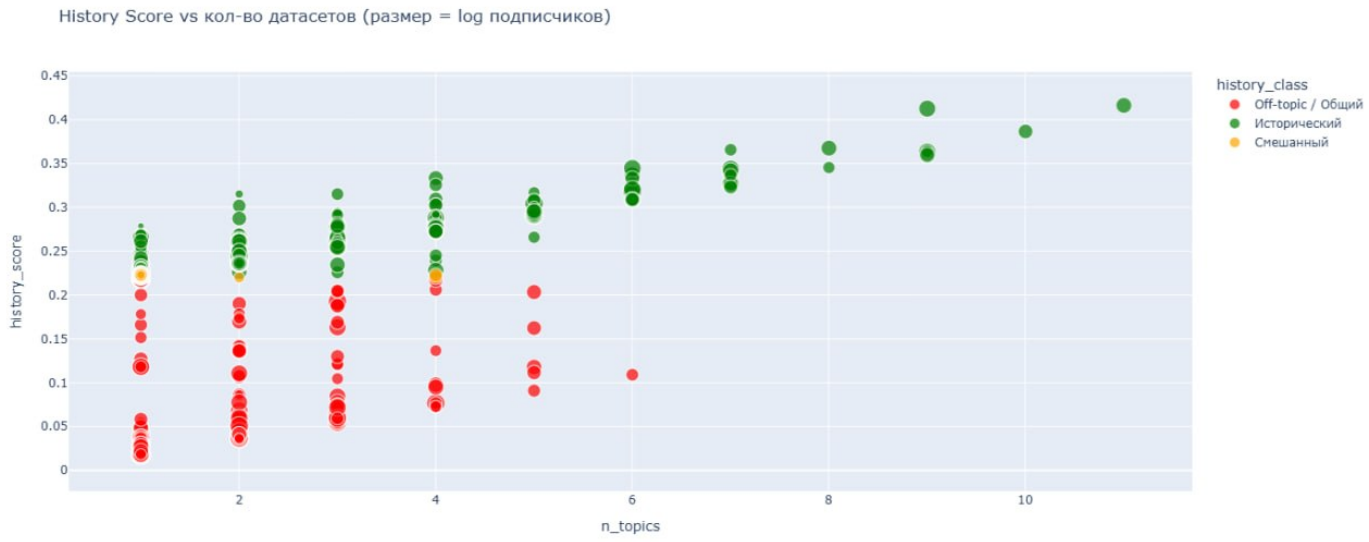

Рис. 22: Связь history_score с тематической широтой канала

7.4 Покрытие канала vs подписчики

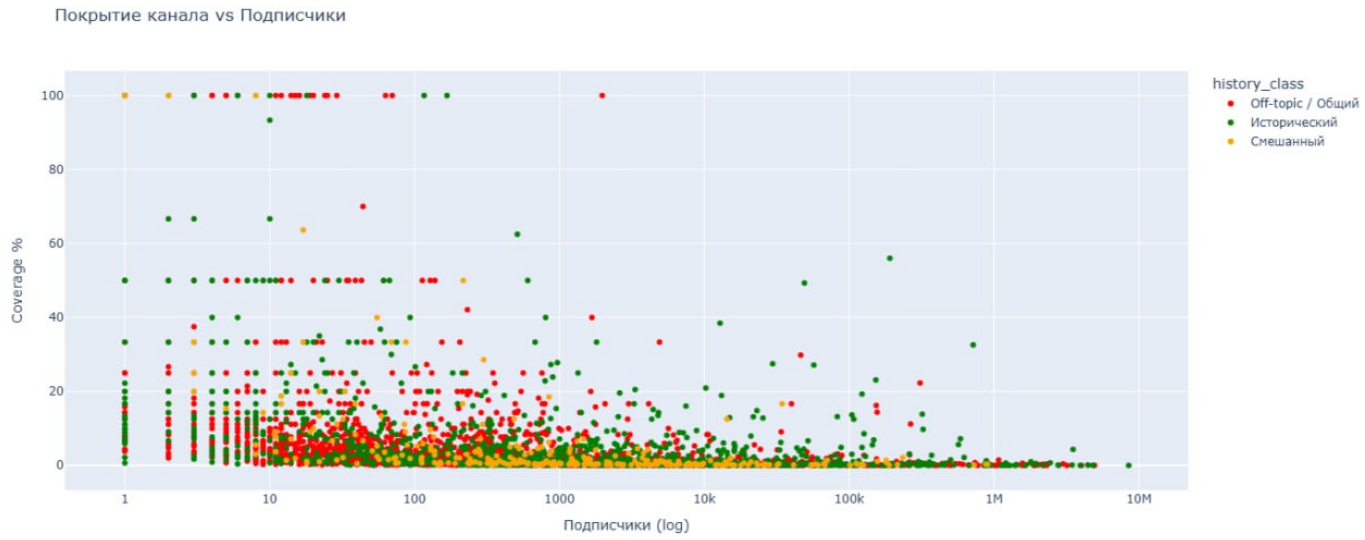

Рис. 23: Связь покрытия и размера канала

8 Формирование пула репрезентативных каналов

8.1 Воронка отбора

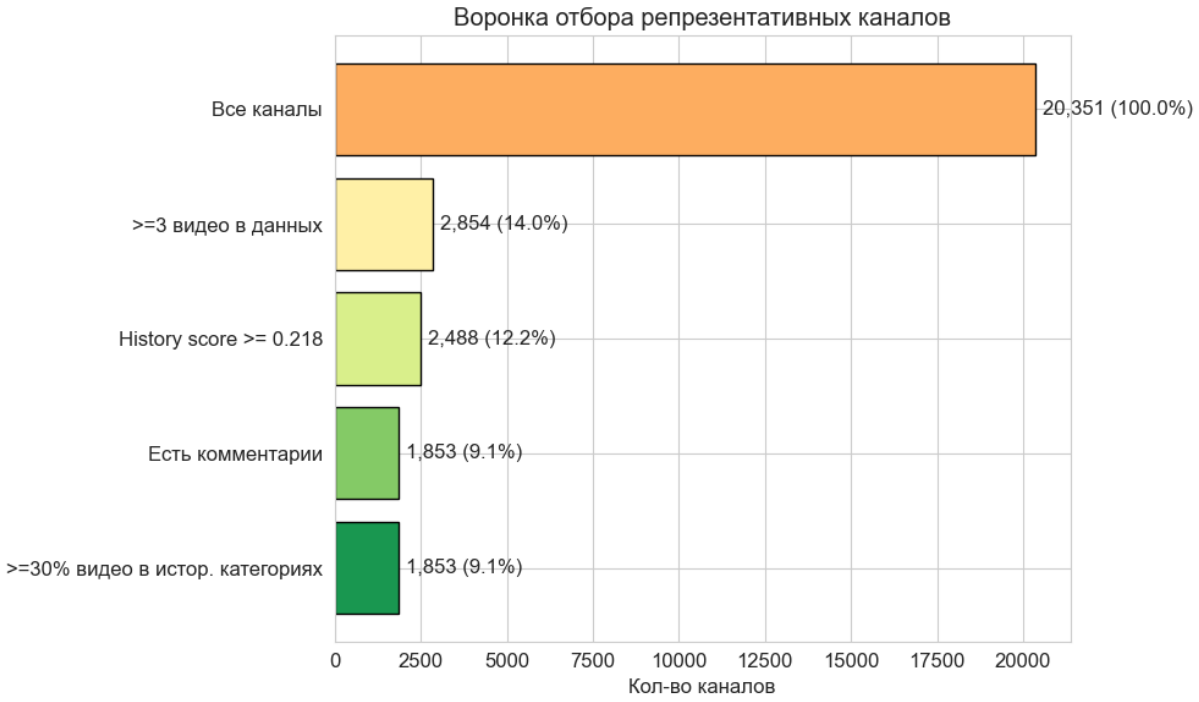

Рис. 24: Этапы формирования пула

8.2 Сравнение пула с исключёнными каналами

Таблица 10: Сравнение пула «репрезентативных» каналов с исключёнными

	В пуле	**Исключены**	**Комментарий**
Число каналов	1,853	18,498	Пул — 9 % от общего числа
Медиана видео	5.0	1.0	В пуле — больше видео
Медиана покрытия, %	1.25	1.39	Покрытие низкое в обеих группах
Медиана подписчиков	4,780	301	В пуле — более крупные каналы
Всего видео	18,871	26,090	Пул покрывает меньше видео
Медиана history_score	0.25	0.22	Пул слегка более «исторический»

Таблица 11: Покрытие пулом данных

Метрика	**Значение**
Видео в пуле	18,871 из 44,961 (42.0 %)
Комментарии в пуле	2,027,456 из 4,825,616 (42.0 %)

8.3 Top каналы пула

Таблица 12: Top-30 каналов пула по подписчикам

	Канал	Подписчики	Видео	Датасетов
1	Black History	48,900	517	11
2	ИСТОРИЯ.РФ	206,000	905	10
3	Городской методический центр	51,100	4,752	10
4	tvsoyuz	673,000	167,610	10
5	Вместе МИР	499,000	5,380	10
6	ПРО История	35,000	130	8
7	КАК БЫЛО НА ВОЙНЕ	32	83	7
8	История Онлайн	139,000	159	8
9	Письма с фронта	152,000	212	8
10	Исторический факт	4,590	1,449	8

Таблица 13: Top-20 каналов по покрытию (min 5 видео в датасете)

	Канал	Видео в DS	Coverage %	Подписчики
1	Государственный музей обороны Москвы	28	75.0 %	7,440
2	История России	13	50.0 %	4,470
3	Дмитровское ТВ	13	45.0 %	17,200
4	За Мир	10	40.0 %	2,490
5	Телеканал ICTV	9	35.0 %	5,230,000
6	Para Bellum	9	30.0 %	136,000
7	Фронтовая кинолетопись	5	25.0 %	183,000
8	Невский Баталист	4	20.0 %	1,340
9	Real Time History	4	18.0 %	523,000
10	Дмитрий Удав Dmitry Udav	9	75.0 %	209

Таблица 14: Top-50 каналов по history_score

	Канал	**Подписчики**	**Score**	**Класс**
1	Black History	48,900	0.416	Исторический
2	ИСТОРИЯ.РФ	206,000	0.415	Исторический
3	Городской методический центр	51,100	0.387	Исторический
4	tvsoyuz	673,000	0.386	Исторический
5	Вместе МИР	499,000	0.382	Исторический
6	ПРО История	35,000	0.385	Исторический
7	КАК БЫЛО НА ВОЙНЕ	32	0.383	Исторический
8	История Онлайн	139,000	0.377	Исторический
9	Письма с фронта	152,000	0.376	Исторический
10	Исторический факт	4,590	0.369	Исторический

8.4 Покрытие по датасетам

Таблица 15: Статистика покрытия по датасетам

Dataset	**Каналы**	**Медиана видео**	**Медиана coverage %**	**Медиана subs**	**% ка**
Берлин	354	1.00	1.52	7.48	
Курск	1,024	1.00	1.36	6.96	
Ленинград	3,137	1.00	1.45	7.12	
Москва	2,631	1.00	1.52	7.48	
Сталинград	2,149	1.00	1.48	7.25	
Матросов	125	1.00	1.31	6.36	
Рокоссовский	103	1.00	1.31	6.36	
Сталин	1,756	1.00	1.11	6.22	
Жуков	718	1.00	1.25	6.55	
Зоя	321	1.00	1.28	6.68	
ВОВ	18,498	1.00	1.35	7.73	
Мировая война	4,108	1.00	1.35	7.73	

9 Ключевое ограничение: смещение выборки

Важное предупреждение о репрезентативности

YouTube активно удаляет каналы, связанные с исторической и политической тематикой, особенно после 2022 года. В их числе:

- Канал **Юрия Подоляки** (один из крупнейших русскоязычных историко-аналитических блогов);
- Каналы, аффилированные с государственными СМИ отдельных стран;
- Авторы, чьи трактовки исторических событий были признаны платформой «не соответствующими правилам».

Это приводит к **систематическому смещению выборки**: в датасете представлены преимущественно:

1. Небольшие региональные каналы (музеи, библиотеки, местные СМИ);
2. Каналы с «нейтральной» или академической подачей;
3. Контент, загруженный до введения жёстких модерационных политик.

Следствие: любые выводы о «доминирующих нарративах» или «эволюции дискурса» следует интерпретировать с учётом того, что наиболее влиятельные и поляризующие голоса могут быть исключены из анализа.

9.1 Количественная оценка смещения

- Пул репрезентативных каналов составляет лишь 9 % от общего числа (1,853 из 22,913)
- Медианное покрытие каналов остаётся низким (1.25–1.39 %) даже после фильтрации
- В пуле представлены преимущественно более крупные каналы (медиана 4,780 подписчиков против 301)

10 План дальнейшей работы

10.1 Этап 1: Углублённый NLP-анализ

1. **Тональность и эмоции**: применение мультиязычных моделей (RuBERT, XLM-R) для классификации комментариев по шкалам:
   - Полярность (негатив/нейтраль/позитив);
   - Эмоции (гнев, печаль, гордость, ностальгия);
   - Агрессивность / токсичность.
2. **Тематическое моделирование**: LDA / BERTopic для выделения скрытых тем в описаниях видео и комментариях.
3. **Извлечение сущностей**: распознавание имён, географических названий, дат для построения темпорально-пространственных графов.

10.2 Этап 2: Сетевой анализ

- Построение графа каналов на основе:
  - Совместных упоминаний в комментариях;
  - Пересечений аудитории (по авторам комментариев);
  - Ссылок в описаниях видео.
- Расчёт метрик центральности (PageRank, Betweenness) для выявления «инфлюенсеров».
- Выявление сообществ (Louvain, Leiden) и анализ их эволюции во времени.

10.3 Этап 3: Завершение работы

- Создание интерактивного веб-блога с методологией и визуализациями.

10.4 Этика и открытость

- Все пользовательские данные анонимизированы: удаляются `author_id`, IP-адреса, геолокация.
- Исходный код анализа и визуализаций будет опубликован на GitHub.
- Датасет доступен на Kaggle: https://www.kaggle.com/datasets/lavrovalexei/my-dataset
- Ссылка на GitHub-репозиторий проекта

11 Заключение

Проведённый разведочный анализ подтверждает техническую возможность исследования эволюции исторической памяти на основе данных русскоязычного YouTube. Ключевые выводы:

1. **Данные богаты, но фрагментарны**: 4,8 млн комментариев предоставляют уникальную возможность для анализа дискурса, однако низкое покрытие каналов и удаление контента платформой вносят систематические смещения.

2. **Метрика `history_score` работает**: классификация каналов позволяет отделить релевантный контент от шума, но требует тонкой настройки порогов под конкретные исследовательские вопросы.

3. **Временная динамика чувствительна к внешним событиям**: пики активности комментариев коррелируют с юбилеями и геополитическими кризисами, что открывает путь к каузальному анализу.

4. **Репрезентативность ограничена**: отсутствие в выборке крупных удалённых каналов (Подоляка и др.) означает, что анализ отражает преимущественно «умеренный» сегмент дискурса. Это ограничение должно явно учитываться при интерпретации результатов.

Дальнейшая работа будет сосредоточена на интеграции NLP-методов, построении сетевых моделей и создании открытой веб-платформы для визуализации и совместного исследования.

A Приложение A: Глоссарий терминов

`video_id` Уникальный идентификатор видео на YouTube (11 символов).

`engagement rate` Метрика вовлечённости: $(likes + comments)/views$.

`coverage_pct` Доля видео канала, попавших в выборку, относительно общего числа видео на канале.

`history_score` Композитная метрика релевантности канала исторической тематике (формула (1)).

Нарратив Устойчивая смысловая конструкция, описывающая событие или личность в определённой интерпретации.

Список литературы

[1] YouTube Data API v3. https://developers.google.com/youtube/v3

[2] Honnibal M., Montani I. spaCy: Industrial-strength Natural Language Processing in Python. 2017. https://spacy.io

[3] Grootendorst M. BERTopic: Neural topic modeling with a class-based TF-IDF procedure. arXiv:2203.05794, 2022.

[4] Hagberg A., Swart P., Chult D. Exploring network structure, dynamics, and function using NetworkX. Proceedings of the 7th Python in Science Conference, 2008.

[5] Assmann J. Cultural Memory and Early Civilization. Cambridge University Press, 2011.

[6] Колесниченко А. В. Политический дискурс русскоязычного YouTube: методы и результаты анализа // Мониторинг общественного мнения, 2021. № 3. С. 45–67.