

Эволюция исторической памяти о Великой Отечественной войне в русскоязычном сегменте YouTube (2010–2025)

Отчёт по глубинному NLP-анализу и моделированию дискурса

Исследовательская группа

Таряник Антон Александрович

Дубовик Никита Спартакович

Бессонов Александр Русланович

15 мая 2026 г.

Аннотация

В данном отчёте представлены результаты глубинного анализа 4,8 млн комментариев русскоязычного сегмента YouTube с использованием методов обработки естественного языка (NLP), теории графов и математической статистики.

Если на этапе разведочного анализа (EDA) решалась задача структурирования данных, то целью текущего этапа является доказательное математическое моделирование эволюции исторической памяти. Работа выстроена вокруг сквозного тезиса: в период с 2010 по 2025 год память о Великой Отечественной войне трансформировалась из консенсусного коммеморативного (памятного) нарратива в секьюритизированный инструмент идеологической поляризации и легитимации современных политических конфликтов.

Отчёт включает 16 верифицированных гипотез, разделённых на четыре блока: темпоральность и актуализация, топология социального одобрения, инфраструктура дискурса и лингвистическая дивергенция (фрейминг). Для каждого эксперимента приведено строгое математическое обоснование, адаптированное для междисциплинарного (в т.ч. исторического) анализа.

СОДЕРЖАНИЕ

1	Введение: Историческая память как вычислимая величина	3
2	Блок I. Темпоральность и Актуализация памяти	4
2.1	Гипотеза 1: Индекс ретроспективной актуализации (Презентизм)	4
2.2	Гипотеза 2: Семантическая структура памяти (BERTopic)	5
2.3	Гипотеза 3: Коэффициент глубины дискуссии (Морфология дискурса)	6
3	Блок II. Социальное одобрение и Топология конфликта	8
3.1	Гипотезы 4 и 5: Эволюция нормы социальной терпимости к агрессии .	8
3.2	Гипотеза 6: Деконструкция вклада Союзников	9
3.3	Гипотеза 7: Конфликтотенность национальных локусов	10
4	Блок III. Инфраструктура дискурса	12
4.1	Гипотезы 8, 9, 10: Time Lag, Пузыри и Масштаб	12
4.2	Гипотеза 11: Морфология пользователей (Сетевое Ядро)	13
4.3	Гипотеза 12: Историческая терапия в период социального шока	14
5	Блок IV. Лингвистика и Фрейминг памяти	16
5.1	Гипотеза 13: Индекс структурной экспрессивности	16
5.2	Гипотеза 14: Смещение фрейминга (Матрица PMI)	16
5.3	Гипотеза 15: Лингвистическая дивергенция (Log-Odds Ratio)	17
5.4	Гипотеза 16: Ландшафт исторической памяти	17
6	Заключение: Историческая память в условиях геополитического кризиса	19
	Доступность данных и исходного кода	20

1 ВВЕДЕНИЕ: ИСТОРИЧЕСКАЯ ПАМЯТЬ КАК ВЫЧИСЛИМАЯ ВЕЛИЧИНА

Традиционная историография изучает память через качественный анализ текстов, мемориалов и официальных речей. Однако цифровая среда (YouTube) позволяет подойти к исторической памяти как к измеримому, многомерному массиву данных. Наша задача — перевести гуманитарные категории («радикализация», «переписывание истории», «поляризация») на строгий язык математической статистики.

Для этого мы применяем методы векторного представления слов (Embeddings), вероятностные модели распределения тем (BERTopic), метрики теории информации (PMI) и сетевого анализа. Итогом становится не просто описание того, *что* говорят пользователи, а математическое доказательство того, *как структурно изменился* сам язык описания прошлого в ответ на политические события, в том числе 2014 (присоединение Крыма) и 2022 (начало СВО) годов.

2 Блок I. Темпоральность и Актуализация памяти

В данном блоке исследуется, как прошлое проникает в настоящее, и как меняется структура ведения дискуссий.

2.1 Гипотеза 1: Индекс ретроспективной актуализации (Презентизм)

Идея: Историческая память не существует в вакууме. Мы предполагаем, что обсуждение ВОВ всё чаще используется для объяснения текущих политических событий (эффект презентизма).

Математика и методология: Использование абсолютного числа вхождений современных политических терминов (Путин, Байден, НАТО, СВО и др.) искажает картину, так как длинные тексты статистически содержат больше слов. Мы вводим нормированную метрику — *плотность актуализации* на 1000 слов (промилле):

$$Index_{act} = \left(\frac{\sum_{i=1}^N I(w_i \in Dict_{modern})}{N_{words}} \right) \times 1000 \quad (1)$$

где I — функция-индикатор (равна 1, если токен принадлежит словарю современности), а N_{words} — длина текста.




Рис. 1: Индекс ретроспективной актуализации (2010–2025)

Историческая интерпретация: График блестяще доказывает гипотезу. Мы видим два чётких разрыва: скачок актуализации весной 2014 года (Крым и Донбасс) и беспрецедентный взлёт в феврале 2022 года. История ВОВ перестала быть изолированным прошлым, превратившись в язык описания и объяснения текущего геополитического конфликта.

2.2 Гипотеза 2: Семантическая структура памяти (BERTopic)

Идея: Выявление латентных кластеров обсуждения (на примере Блокады Ленинграда) без заранее заданных словарей.

Математика и методология: Простой поиск слов вырывает их из контекста. Мы используем модель BERTopic, основанную на трансформерах (Sentence-Transformers). Тексты переводятся в многомерные векторы, сжимаются алгоритмом UMAP и кластеризуются через алгоритм HDBSCAN. Важность слов в кластере определяется через модифицированную метрику *c-TF-IDF*:

$$c\text{-}TF\text{-}IDF_i = \frac{t_i}{w_i} \times \log \left(1 + \frac{A}{t_a} \right) \quad (2)$$

где:

- t_i — частота конкретного слова в одном тематическом кластере (сколько раз оно встретилось в обсуждении конкретной темы);
- w_i — общее количество слов в этом кластере;
- A — среднее количество слов на один кластер по всему массиву данных;
- t_a — общая частота этого же слова во всех остальных темах (насколько слово уникально именно для этой темы, а не является фоновым шумом).

Таким образом, метрика штрафует общеупотребительные слова (вроде «война» или «люди») и выводит наверх те термины, которые характеризуют исключительно данную подтему (например, «карточки» или «завод»). Это позволяет объединить смыслы. Например, комментарии «людям нечего было есть» и «ужасный голод» попадут в один кластер, даже не имея общих слов.



Рис. 2: Эволюция латентных тем Блокады Ленинграда

Историческая интерпретация: Алгоритм отделил официальный мемориальный фон («героизм», «память») от социальной истории. Выявлены мощные кластеры, посвящённые бытовому выживанию (заводы, пайковые карточки, дети). Всплеск активности по этим низовым темам в 2020–2024 гг. говорит о запросе общества на «человеческое», а не монументальное измерение войны.

2.3 Гипотеза 3: Коэффициент глубины дискуссии (Морфология дискурса)

Идея: Оценка перехода аудитории от монологичных высказываний («спасибо деду») к ожесточённым спорам (холиварами).

Математика и методология: В теории графов диалогичность сети измеряется через отношение дочерних узлов к корневым. Мы вводим *Reply-to-Root Ratio*:

$$R_{depth} = \frac{V_{replies}}{V_{roots}} \quad (3)$$

где $V_{replies}$ (*Volume*) — общее количество дочерних комментариев (ответов на чужие реплики), а V_{roots} — количество корневых комментариев, оставленных непосредственно под видео.

Для справки: *Эхо-камера* в сетевом анализе — это замкнутая информационная среда, в которой участники сталкиваются преимущественно с мнениями, подкрепляющими их собственные, а альтернативные взгляды либо игнорируются, либо становятся объектом коллективной агрессии. В метриках графов это выражается в формировании аномально длинных ветвей ответов (холиварами), где пользователи группируются для травли оппонентов. Рост $R_{depth} \rightarrow 1$ математически доказывает формирование плотных эхо-камер и дискуссионных ветвей.




Рис. 3: Морфология дискурса: Переход от высказываний к столкновениям

Историческая интерпретация: До 2014 года коэффициент глубины находился около нуля. Начиная с 2014 года, он совершает огромный скачок, стабилизируясь на уровне 0.8–1.0. Это означает тотальное изменение топологии общения: историческая тематика окончательно стала зоной поляризованных дебатов.

3 Блок II. Социальное одобрение и Топология конфликта

3.1 Гипотезы 4 и 5: Эволюция нормы социальной терпимости к агрессии

Идея: Выяснить, получает ли агрессивная историческая риторика социальное одобрение «молчаливого большинства» (через лайки).

Математика и методология: Вводится *Индекс конфликтности* (нормализованная частота обсценной и радикальной лексики). Использование абсолютного числа лайков недопустимо из-за «эффекта масштаба»: средний комментарий на канале-миллионнике соберёт больше лайков, чем гениальный анализ на нишевом канале. Поэтому мы рассчитываем индекс для *внутри-канальных квантилей*. Это значит, что для каждого отдельного видео мы берём только 10 % самых популярных (залайканных) комментариев местной аудитории.

$$\bar{H}_{top} = \frac{1}{|S_{top}|} \sum_{c \in S_{top}} \frac{Count(Slur)}{Length(c)} \quad (4)$$

где:

- S_{top} — множество комментариев, вошедших в верхний дециль (Top-10 %) по лайкам под конкретным видео;
- $|S_{top}|$ — количество таких комментариев;
- c — каждый конкретный комментарий из этого множества, по которому идёт суммирование (Σ);
- $Count(Slur)$ — количество обсценных или радикальных слов в комментарии c ;
- $Length(c)$ — общая длина комментария в словах (для нормировки).




Рис. 4: Социальное одобрение резкой риторики и динамика терпимости

Историческая интерпретация: Результат строго контринтуитивен. Наибольшую поддержку (лайки) получают комментарии с *наименьшей* агрессией. Общество вознаграждает сарказм и артикулированную позицию, оставляя прямые оскорбления на уровне маргинального шума. Динамика с 2014 по 2024 год показывает общий рост напряжённости (фон растёт), но норма социального одобрения радикальности не сломана.

3.2 Гипотеза 6: Деконструкция вклада Союзников

Идея: Оценка частоты ревизионистского нарратива об обесценивании действий стран антигитлеровской коалиции (ленд-лиз).

Математика и методология: Обычное пересечение словарей (наличие слов «США» и «тушёнка» в одном тексте) даёт ложные срабатывания (например, «США помогли тушёнкой, спасибо»). Применяется *оконный синтаксический поиск* (*Window-based Co-occurrence*):

$$I_{deval} = 1 \iff \min(|Pos(W_{ally}) - Pos(W_{deval})|) \leq 7 \quad (5)$$

Индикатор наличия нарратива (I_{deval}) равен единице только в том случае, если математическое расстояние — то есть разница позиций слов в тексте $|Pos(W_{ally}) - Pos(W_{deval})|$ — между словом-маркером союзников (например, «США» или «ленд-лиз») и словом девальвации (например, «тушёнка», «отсиживались») составляет не более 7 слов.

Для исторической интерпретации это означает критически важную вещь: мы не просто фиксируем, что эти слова есть в одном большом тексте (что могло бы дать

ошибку: «США помогали, спасибо за тушёнку»). Ограничение дистанции гарантирует, что слова грамматически и семантически связаны в одном предложении, и удар направлен конкретно на союзника. Ограничение дистанции между маркерами субъекта и девальвации строго фиксирует смысловую направленность атаки.




Рис. 5: Деконструкция вклада Союзников (Оконный поиск)

Историческая интерпретация: Нарратив девальвации носит волнообразный характер. Его снижение в конце 2010-х сменилось плавным ренессансом к 2024 году, что математически отражает идеологический конструкт «Россия всегда воевала в одиночку против коллективного Запада».

3.3 Гипотеза 7: Конфликтогенность национальных локусов

Идея: Как этно-географические маркеры работают как триггеры агрессии в историческом контексте.

Математика и методология: Рассчитывается дельта $\Delta H_E = \bar{H}_{Entity} - \bar{H}_{Global}$ — превышение конфликтогенности вокруг конкретной сущности (региона) над глобальным средним индексом по датасету.




Рис. 6: Конфликтность национальных локусов памяти

Историческая интерпретация: Демонстрация распада концепта «общей советской Победы». Локус «Украина» вызывает аномальный уровень агрессии (почти в 2.5 раза выше фона). В то же время Беларусь, Кавказ и Средняя Азия остаются в зоне спокойного, комплементарного консенсуса.

4 Блок III. ИНФРАСТРУКТУРА ДИСКУРСА

4.1 Гипотезы 8, 9, 10: Time Lag, Пузыри и Масштаб

Идея: Зависимость агрессии от возраста видео, исторической темы и размера канала.

Математика и методология: Многофакторная агрегация. Возраст комментария вычисляется как $\Delta T_{lag} = Date_{comment} - Date_{video}$. Размер канала аппроксимируется через процентилю охвата аудитории $P(V_{channel})$.

- **Эффект старения (Time Lag):** Видео старше 1 года превращаются в «идеологические отстойники» (индекс агрессии растёт почти в 2 раза).




Рис. 7: Эффект старения видео (Эхо-камеры старых тредов)

- **Тематика (Пузыри):** Макро-символы (Берлин, Сталинград) максимально политизированы. Персоналии (кроме Сталина) остаются академичными.




Рис. 8: Топология конфликтности (Рейтинг исторических сюжетов)

- **Масштаб:** На мега-каналах политизация в 2 раза выше (12%), чем на нишевых (6%). Массовая аудитория размывает исторический контекст.




Рис. 9: Степень политизации истории от масштаба канала

4.2 Гипотеза 11: Морфология пользователей (Сетевое Ядро)

Идея: Отказ от журналистского термина «боты» в пользу эмпирической сегментации сетевой активности.

Математика и методология: На основе распределения Парето рассчитывается эмпирическая функция распределения активности $F(u)$. Выделяется U_{core} (сверхактивное ядро, > 95 процентиля). Оценивается вклад этой микро-группы в общий объём конфликтности.




Рис. 10: Вклад сегментов пользователей в генерацию агрессии

Историческая интерпретация: Абсолютное меньшинство управляет дискурсом. Микроскопическое ядро генерирует подавляющую долю агрессивного исторического контента, создавая у пассивного большинства иллюзию тотальной радикализации общества. Важно отметить, что в дальнейшей перспективе именно этот математически изолированный сегмент «сверхактивного ядра» (U_{core}) может стать идеальной эмпирической базой для выявления и исследования организованных сетей ботов (так называемых «фабрик троллей»), целенаправленно формирующих нужный информационный фон в исторической политике.

4.3 Гипотеза 12: Историческая терапия в период социального шока

Идея: Обращение к прошлым победам как к психологическому антидепрессанту в моменты социальных кризисов (осень 2022, мобилизация).

Математика и методология: Применение *Zero-Shot классификации* на базе NLI-модели mDeBERTa-v3. Модель рассчитывает вероятности принадлежности текста к скрытым психологическим состояниям: $\arg \max_c P(c|text)$.




Рис. 11: Историческая терапия в период социального шока (Осень 2022)

Историческая интерпретация: На фоне доминирующего нарратива тревожности, именно в неделю объявления мобилизации фиксируется статистически значимый всплеск апелляции к историческому триумфу («победили тогда, победим и сейчас»). Воспоминания о ВОВ выступили механизмом социальной стабилизации.

5 Блок IV. Лингвистика и Фрейминг памяти

5.1 Гипотеза 13: Индекс структурной экспрессивности

Идея: Анализ синтаксического (не семантического!) надрыва аудитории.

Математика и методология: Вычисляется индекс синтаксической напряжённости: $E = (N_{punct}/N_{words}) \times 100$, где учитываются множественные знаки препинания и использование заглавных букв.

Историческая интерпретация: Глобальный тренд указывает на «остывание» синтаксиса рунета за 15 лет (меньше крика). Однако 2014 год выделяется мощным пиком истерики. К 2022 году дискурс стал более политизированным идеологически, но структурно более «холодным» и рутинным.

5.2 Гипотеза 14: Смещение фрейминга (Матрица PMI)

Идея: Концепт абсолютного исторического зла отрывается от Германии 1940-х и привязывается к современным оппонентам.

Математика и методология: Используется *Pointwise Mutual Information (PMI)*, измеряющая степень неслучайности совместного появления слов:

$$PMI(A, B) = \log_2 \left(\frac{P(A \cap B)}{P(A) \cdot P(B)} \right) \quad (6)$$

Если $PMI > 0$, термины устойчиво притягиваются друг к другу в языковой модели рунета.




Рис. 12: Эволюция фрейминга «Фашизм» (Pointwise Mutual Information)

Историческая интерпретация: Блестящее математическое доказательство рефрейминга. Связь термина «фашизм/нацизм» с Германией (серая линия) плавно деградирует. С 2014 года происходит резкая, скачкообразная привязка этого концепта к Украине и коллективному Западу. Исторический термин окончательно превратился в современный ярлык.

5.3 Гипотеза 15: Лингвистическая дивергенция (Log-Odds Ratio)

Идея: Распад единого языка памяти на два изолированных словаря у противоборствующих идеологических групп.

Математика и методология: Стандартный TF-IDF здесь бесполезен. Применяется метод логарифмических шансов с априорным распределением Дирихле (Mongoe et al., 2008):

$$\delta_w = \log \left(\frac{y_w + \alpha_w}{N_1 - y_w + \alpha_w} \right) - \log \left(\frac{z_w + \alpha_w}{N_2 - z_w + \alpha_w} \right) \quad (7)$$

Параметр α_w сглаживает шум от служебных слов. Формула находит токены, статистически *эксклюзивные* для конкретного вектора.




Рис. 13: Лингвистическая дивергенция (Log-Odds Ratio)

Историческая интерпретация: Выявлены два абсолютно непересекающихся «новояза». *Официально-патриотический (прогосударственный)* дискурс апеллирует к легитимным, монументальным терминам (*героические, защитники, денацификация*). *Антисистемный (оппозиционно-радикальный)* вектор формирует язык жёсткой деконструкции и расчеловечивания (*орки, рашисты, бункер*). Поляризация памяти зашла так далеко, что группы описывают одно и то же историческое прошлое, используя совершенно разные языковые модели.

5.4 Гипотеза 16: Ландшафт исторической памяти

Идея: Составление двумерной карты исторических сюжетов для выявления зон «чистой истории» и зон политизации.

Математика и методология: Scatter-plot матрица. Ось X — «Индекс исторической глубины» (плотность дат и фамилий). Ось Y — «Индекс конфликтогенности». Для справки: *Scatter-plot (диаграмма рассеяния)* — это тип математического графика, где каждая точка представляет собой отдельный объект (в нашем случае — исторический сюжет или датасет). Положение точки на плоскости определяется двумя переменными, отложенными по осям X и Y. Это позволяет визуально оценить наличие корреляций, а также выделить кластеры объектов со схожими свойствами.




Рис. 14: Ландшафт памяти: Академичность vs Идеологизация

Историческая интерпретация: Выделены полярные зоны. Левый верхний угол («Зона холливаров» — Берлин, Сталинград) характеризуется максимальной агрессией и вымыванием фактологии. Правый нижний угол («Академическая гавань» — Рокоссовский) сохраняет предметность дискуссии без перехода на личности.

6 ЗАКЛЮЧЕНИЕ: ИСТОРИЧЕСКАЯ ПАМЯТЬ В УСЛОВИЯХ ГЕОПОЛИТИЧЕСКОГО КРИЗИСА

Применение строгих методов математической статистики и NLP к массиву русскоязычного YouTube (2010–2025 гг.) позволяет сделать фундаментальные выводы о трансформации исторической памяти в современной России:

1. **Секьюритизация и инструментализация памяти.** Память о Великой Отечественной войне окончательно утратила статус автономного мемориального пространства. В период с 2014 по 2024 гг. она была конвертирована в язык объяснения современных конфликтов. Индекс ретроспективной актуализации (Г1) и метрика РМІ (Г14) математически доказывают, что терминологический аппарат 1941–1945 годов (нацизм, фашизм, защита Отечества) был полностью редуцирован и экстраполирован на геополитических оппонентов РФ.
2. **Фрагментация консенсуса.** Данные фиксируют распад советского концепта «единой Победы». Выявлена пространственная политизация: исторические сюжеты, связанные с Украиной, генерируют аномальный уровень агрессии, в то время как вклад других республик остаётся в зоне консенсуса (Г7). Вклад западных союзников подвергается системной ревизии в соответствии с логикой политического момента (Г6).
3. **Сетевая поляризация меньшинством.** Топология дискурса радикально изменилась после 2014 года (Г3). Однако анализ активности доказывает, что радикализация управляется крайне узким ядром пользователей (< 5 %, Г11). Молчаливое большинство аудитории при этом не поддерживает крайние формы конфликтности, вознаграждая социальным капиталом (лайками) более умеренную и аргументированную риторику (Г4, Г5).
4. **История как экзистенциальный антидепрессант.** В моменты пиковых социальных шоков (начало мобилизации осенью 2022 года) исторический дискурс берёт на себя терапевтическую функцию (Г12). Общество инстинктивно обращается к воспоминаниям о победе над экзистенциальным злом как к механизму преодоления тревоги и страха перед будущим.

Итог: В русскоязычном цифровом пространстве 2025 года Великая Отечественная война обсуждается не как завершённое событие прошлого, а как метафора и полигон для незавершённого глобального конфликта настоящего.

Дополнительно: С графиками в высоком качестве, а также опорными словарями можно будет ознакомиться в нашем репозитории на GitHub.

ДОСТУПНОСТЬ ДАННЫХ И ИСХОДНОГО КОДА

В соответствии с принципами открытой науки (Open Science), весь исходный код, пайплайны обработки естественного языка и сгенерированные интерактивные визуализации доступны для академического сообщества в публичном репозитории проекта.

Ссылка на репозиторий GitHub:

<https://github.com/Toxele/Russian-History-Project-2026-by-Taryanik-Dubovik-and-Bessonov>

СПИСОК ЛИТЕРАТУРЫ

- [1] YouTube Data API v3. <https://developers.google.com/youtube/v3>
- [2] Grootendorst M. BERTopic: Neural topic modeling with a class-based TF-IDF procedure. arXiv:2203.05794, 2022.
- [3] Monroe B. L., Colaresi M. P., Quinn K. M. Fightin' words: Lexical feature selection and evaluation for identifying the content of political conflict // Political Analysis. 2008. Vol. 16, no. 4. P. 372–403.
- [4] Church K. W., Hanks P. Word association norms, mutual information, and lexicography // Computational linguistics. 1990. Vol. 16, no. 1. P. 22–29.
- [5] Assmann J. Cultural Memory and Early Civilization. Cambridge University Press, 2011.
- [6] Колесниченко А. В. Политический дискурс русскоязычного YouTube: методы и результаты анализа // Мониторинг общественного мнения, 2021. № 3. С. 45–67.